

用于低光照图像增强的零参考深度曲线估计

郭春乐^{1,2*} 李重义^{1,2*} 郭继昌^{1†} 陈振强³ 侯俊辉² Sam Kwong² 从润民⁴

¹ 北京信息科学与技术国家研究中心 (BIIT), 天津大学 ² 香港城市大学 ³ 南洋理工大学 ⁴ 北京交通大学

{guochunle, lichongyi, jcguo}@tju.edu.cn ccloy@ntu.edu.sg

{jh.hou, cssamk}@cityu.edu.hk rmcong@bjtu.edu.cn

https://li-chongyi.github.io/Proj_Zero-DCE.html/

摘要

本文提出了一种新颖的方法, 即零参考深度曲线估计 (Zero-Reference Deep Curve Estimation, Zero-DCE), 该方法将图像增强建模为利用深度网络进行特定于图像的曲线估计任务。我们的方法训练了一个轻量级深度网络 DCE-Net, 用于对给定图像进行动态范围调整的逐像素和高阶曲线估计。该曲线估计设计专门考虑了像素值范围、单调性和可微性。Zero-DCE 的优势在于其对参考图像的假设较为宽松, 即在训练过程中不需要任何成对或不成对的数据。这是通过一套精心设计的非参考损失函数实现的, 这些函数隐式地衡量增强质量并驱动网络的学习。由于图像增强可以通过直观且简单的非线性曲线映射实现, 因此该方法效率很高。尽管方法简单, 但我们证明了其在不同光照条件下具有良好的泛化能力。在多个基准数据集上的大量实验从定性和定量两个方面都表明, 与最先进的方法相比, 我们的方法具有优势。此外, 还讨论了我们的 Zero-DCE 在暗光下人脸检测方面的潜在应用价值。

1. 引言

由于不可避免的环境和/或技术限制, 许多照片往往在次优的光照条件下拍摄。这些情况包括环境中照明不足且不均匀、物体置于极端逆光背景下的位置不当, 以及图像拍摄时的曝光不足。此类低光照照片会遭受美学质量下降和信息传递不 satisfactory 的问题。前者影响观看者的体验, 而后者则导致错误信息的传递, 例如不准确的目标/人脸识别。

[†]*前两位作者对本工作贡献相当。 Jichang Guo (jcguo@tju.edu.cn) 为通讯作者。




图 1: 典型低光照图像上的视觉对比。所提出的 Zero-DCE 在亮度、色彩、对比度和自然度方面均取得了令人满意的视觉效果, 而现有方法要么无法应对极端背光, 要么会产生色彩伪影。与其他基于深度学习的方法不同, 我们的方法无需任何参考图像即可进行训练。

在本研究中, 我们提出了一种新颖的基于深度学习的方法——零参考深度曲线估计 (Zero-Reference Deep Curve Estimation, Zero-DCE), 用于低光照图像增强。该方法能够应对包括不均匀和照明不良在内的各种光照条件。与执行图像到图像的映射不同, 我们将该任务重新表述为特定于图像的曲线估计问题。具体而言, 所提方法以低光照图像作为输入, 并生成高阶曲线作为输出。随后, 利用这些曲线对输入的动态范围进行逐像素调整, 从而获得增强后的图像。曲线估计经过精心 formulation, 以保持增强图像的范围并保留相邻像素的对比度。重要的是, 它

是可微的,因此我们可以通过深度卷积神经网络学习曲线的可调整参数。所提出的网络结构轻量级,并且可以迭代应用以逼近高阶曲线,从而实现更稳健、更精确的动态范围调整。

我们基于深度学习的方法的一个独特优势是零参考,即,与现有的基于 CNN 的方法 [28,32] 和基于 GAN 的方法 [12,38] 不同,它在训练过程中不需要任何成对甚至不成对的数据。这是通过一套专门设计的非参考损失函数实现的,包括空间一致性损失、曝光控制损失、颜色恒常性损失和光照平滑度损失,所有这些损失都考虑了光增强的多因素。我们表明,即使是零参考训练,Zero-DCE 仍然能够与其他需要成对或不成对数据进行训练的方法进行竞争。一个包含非均匀照明的低光图像增强示例如图 1 所示。与最先进的方法相比,Zero-DCE 在提亮图像的同时保留了固有的颜色和细节。相比之下,基于 CNN 的方法 [28] 和基于 GAN 的 EnlightenGAN [12] 均产生了欠(人脸部分)和过(橱柜部分)增强。

我们的贡献总结如下。

- 1) 我们提出了第一个不依赖于成对和不成对训练数据的低光照增强网络,从而避免了过拟合的风险。因此,我们的方法能够很好地泛化到各种光照条件下。
- 2) 我们设计了一种图像特定曲线,该曲线能够通过迭代应用自身来实现逐像素及高阶曲线的逼近。此类图像特定曲线能够在宽动态范围内有效地执行映射。
- 3) 我们通过任务特定的无参考损失函数,在缺乏参考图像的情况下展示了训练深度图像增强模型的潜力,这些损失函数间接评估增强质量。

我们的 Zero-DCE 方法在定性和定量指标上均超越了最先进性能。更重要的是,它能够在不增加高计算负担的情况下提升高层视觉任务的性能,例如人脸检测。它能够实时处理图像(在 GPU 上对 $640 \times 480 \times 3$ 尺寸的图像约达到 500 FPS),且训练仅需 30 分钟。

2. 相关工作

传统方法。基于直方图(HE)的方法通过扩展图像的动态范围来执行亮度增强。图像的直方图分布会在全局 [7, 10] 和局部 [15, 27] 层面进行调整。此外,还有各种采用视网膜理论 [13] 的方法,该方法通常将图像分解为反射率和光照分量。反射率分量通常被认为在任何光照条件下都保持一致;因此,光

增强被构建为一个光照估计问题。基于 Retinex 理论,已提出多种方法。Wang 等 [29] 在处理非均匀光照图像时设计了一种保持自然度和信息的方法;Fu 等 [8] 提出了一种加权变分模型,以同时估计输入图像的反射率和光照;Guo 等 [9] 首先通过在 RGB 通道中搜索每个像素的最大强度来估计粗略的光照图,然后利用结构先验对粗略光照图进行细化;Li 等 [19] 提出了一种考虑噪声的新 Retinex 模型,该光照图通过求解优化问题获得。与偶然改变图像直方图分布或依赖潜在不准确物理模型的传统方法不同,所提出的 Zero-DCE 方法通过特定于图像的曲线映射产生增强结果。这种策略能够在对图像进行光增强时不产生不真实的伪影。Yuan 和 Sun [36] 提出了一种自动曝光校正方法,其中给定图像的 S 形曲线由全局优化算法估计,并且每个分割区域通过曲线映射被推至其最佳区域。与 [36] 不同,我们的 Zero-DCE 是一种纯粹的数据驱动方法,在非参考损失函数的设计中考虑了多个光增强因素,因此具有更好的鲁棒性、更宽的图像动态范围调节能力以及更低的计算负担。

数据驱动方法。数据驱动方法主要分为两大分支,即基于 CNN(卷积神经网络)的方法和基于 GAN(生成对抗网络)的方法。大多数基于 CNN 的解决方案依赖成对数据进行监督训练,因此资源消耗较大。通常,这些成对数据是通过自动光线退化、在数据采集过程中更改相机设置或通过图像进行修图来合成数据而 exhaustive(全面)收集的。例如,LL-Net [20] 是在模拟随机 Gamma 校正的数据上训练的;LOL 数据集 [32] 包含成对的低/正常光照图像,其收集过程涉及在图像采集时调整曝光时间和 ISO;MIT-Adobe FiveK 数据集 [3] 包含 5,000 张原始图像,每张图像均有五张由受过专业训练的专家修图生成的图像。

最近,Wang 等 [28] 提出了一种欠曝光照片增强网络,通过估计光照图来实现。该网络使用由三位专家修饰过的成对数据进行训练。可以理解的是,基于成对数据的增光方案在许多方面并不切实际,考虑到收集足够成对数据的高昂成本,以及深度模型训练中可能包含虚假和不真实数据的问题。这些限制反映在基于 CNN 的方法泛化能力较差上。伪影和色偏是常




图2: (a) Zero-DCE的框架。设计了一个DCE-Net来估计一组最佳拟合的增光曲线 (LE曲线), 以迭代增强给定的输入图像。(b, c) 具有不同调整参数 α 和迭代次数 n 的LE曲线。在(c)中, α_1 、 α_2 和 α_3 均等于-1, 而 n 等于4。在每个子图中, 横轴表示输入像素值, 纵轴表示输出像素值。

通常生成于这些方法面对具有不同光照强度的真实世界图像时。

基于无监督生成对抗网络 (GAN) 的方法具有消除训练配对数据需求的优势。EnlightenGAN [12] 是一种基于无监督 GAN 的先驱方法, 它利用非配对的低光/正常光照数据学习增强低光图像。该网络通过采用精心设计的判别器和损失函数进行训练。然而, 基于无监督 GAN 的解决方案通常需要对非配对训练数据进行仔细筛选。

所提出的 Zero-DCE 在三个方面优于现有的数据驱动方法。首先, 它探索了一种新的学习策略, 即需要零参考的学习策略, 从而消除了对成对和无配对数据的需求。其次, 该网络通过采用精心定义的非参考损失函数进行训练。这种策略允许隐式评估输出图像质量, 其结果将用于指导网络学习。第三, 我们的方法高效且成本低廉。这些优势得益于我们的零参考学习框架、轻量级网络结构以及有效的非参考损失函数。

3. 方法论

我们在图 2 中展示了 Zero-DCE 的框架。我们设计了一个深度曲线估计网络 (DCE-Net), 用于在给定输入图像的情况下估计一组最佳拟合的光增强曲线 (LE-curves)。随后, 该框架通过迭代应用这些曲线来映射输入图像的 RGB 通道中的所有像素, 从而获得最终的增强图像。接下来, 我们将在下列章节中详细说明 Zero-DCE 中的关键组件, 即 LE 曲线、DCE-Net 以及无参考损失函数。

3.1. 光增强曲线 (LE-曲线)

受照片编辑软件中曲线调整方法的启发, 我们尝试设计一种曲线, 能够自动将低光照图像映射为其增强版本, 其中自适应性曲线参数仅依赖于输入图像。此类曲线的设计有三个目标: 1) 增强图像的每个像素值应处于 $[0,1]$ 的归一化范围内, 以避免由溢出截断引起的信息丢失; 2) 该曲线应为单调函数, 以保留相邻像素之间的差异 (对比度); 3) 该曲线的形式应尽可能简单, 并且在梯度反向传播过程中可微。

为实现这三个目标, 我们设计了一条二次曲线, 可表示为:

$$LE(I(\mathbf{x}); \alpha) = I(\mathbf{x}) + \alpha I(\mathbf{x})(1 - I(\mathbf{x})), \quad (1)$$

其中 $\mathbf{x}$ 表示像素坐标, $LE(I(\mathbf{x}); \alpha)$ 是给定输入 $I(\mathbf{x})$ 的增强版本, $\alpha \in [-1, 1]$ 是可训练曲线参数, 用于调整 LE-曲线的幅度并控制曝光水平。每个像素被归一化到 $[0, 1]$ 区间, 且所有操作均为逐像素进行。我们分别对三个 RGB 通道应用 LE-曲线, 而非仅作用于照明通道。这种三通道调整能更好地保留固有色彩并降低过饱和的风险。更多细节见补充材料。

图 2(b) 展示了不同调整参数 α 的 LE 曲线示例。显然, 该 LE 曲线符合上述三个目标。此外, LE 曲线能够增加或减少输入图像的动态范围。这一特性不仅有助于增强低光区域, 而且




图 3: 逐像素曲线参数映射的一个示例。为了可视化, 我们平均了所有迭代 ($n=8$) 的曲线参数映射, 并将数值归一化到 $[0, 1]$ 范围。 $\mathcal{A}_n^R$ 、 $\mathcal{A}_n^G$ 和 $\mathcal{A}_n^B$ 分别表示 R、G 和 B 通道的平均最佳拟合曲线参数映射。(b)、(c) 和 (d) 中的映射以热力图形式呈现。

消除过曝伪影。

高阶曲线。式 (1) 中定义的 LE-曲线可迭代应用, 以实现对于具有挑战性的低光照条件进行更灵活的调整。具体而言,

$$LE_n(\mathbf{x}) = LE_{n-1}(\mathbf{x}) + \alpha_n LE_{n-1}(\mathbf{x})(1 - LE_{n-1}(\mathbf{x})), \quad (2)$$

其中 n 为迭代次数, 用于控制曲率。在本文中, 我们将 n 的值设定为 8, 该值足以满意地处理大多数情况。当 n 等于 1 时, 公式 (2) 可退化为公式 (1)。图 2(c) 提供了一个示例, 展示了具有不同 α 和 n 的高阶曲线, 与图 2(b) 中的曲线相比, 这些曲线具有更强的调节能力 (即更大的曲率)。

逐像素曲线。高阶曲线可以调整更宽动态范围内的图像。然而, 这仍然是一种全局调整, 因为 α 用于所有像素。全局映射往往会导致局部区域的过增强或欠增强。为了解决这个问题, 我们将 α 表述为一个逐像素参数, 即, 给定输入图像的每个像素都有一个对应的曲线, 其具有最佳拟合的 α 以调整其动态范围。因此, 公式 (2) 可以重新表述为:

$$LE_n(\mathbf{x}) = LE_{n-1}(\mathbf{x}) + \mathcal{A}_n(\mathbf{x}) LE_{n-1}(\mathbf{x})(1 - LE_{n-1}(\mathbf{x})), \quad (3)$$

其中 $\mathcal{A}$ 是一个与给定图像尺寸相同的参数映射。这里, 我们假设局部区域内的像素具有相同的强度 (即相同的调整曲线), 因此输出结果中的相邻像素仍能保持单调关系。通过这种方式, 逐像素的高阶曲线也符合三个目标。

我们在图 3 中展示了三个通道的估计曲线参数映射示例。如图所示, 不同通道的最佳拟合参数映射具有相似的调整趋势但数值不同, 这表明低光图像三个通道之间存在关联性和差异性。曲线参数映射准确地指示了不同区域的亮度 (例如, 墙上的两个闪光点)。利用拟合映射, 增强版图像可通过逐像素曲线映射直接获得。如图 3(e) 所示, 增强版图像揭示了暗区的内容并保留了亮区。

3.2. DCE-Net

为了学习输入图像与其最佳拟合曲线参数图之间的映射关系, 我们提出了一种深度曲线估计网络 (DCE-Net)。

DCE-Net 的输入是低光照图像, 输出是一组用于相应高阶曲线的逐像素曲线参数图。我们采用了一个具有对称拼接结构的纯 CNN, 包含七个卷积层。每一层由 32 个大小为 3×3 、步长为 1 的卷积核组成, 后接 ReLU 激活函数。我们舍弃了会破坏相邻像素关系的下采样和批归一化层。最后一个卷积层后接 Tanh 激活函数, 该函数为 8 次迭代 ($n=8$) 生成 24 个参数图, 其中每次迭代需要为三个通道分别生成三个曲线参数图。DCE-Net 的详细架构见补充材料。值得注意的是, 对于尺寸为 $256 \times 256 \times 3$ 的输入图像, DCE-Net 仅拥有 79,416 个可训练参数和 5.21G Flops 的计算量。因此, 该网络结构轻量, 可用于移动平台等计算资源受限的设备。

3.3. 无参考损失函数

为了实现 DCE-Net 中的零参考学习, 我们提出了一组可微分的无参考损失函数, 使我们能够评估增强图像的质量。以下四种类型的损失被用于训练我们的 DCE-Net。空间一致性损失。空间一致性损失 L_{spa} 通过保留输入图像与其增强版本之间相邻区域的差异, 鼓励增强图像的空间相干性:

$$L_{spa} = \frac{1}{K} \sum_{i=1}^K \sum_{j \in \Omega(i)} (|Y_i - Y_j| - |I_i - I_j|)^2, \quad (4)$$

其中 K 为局部区域的数量, $\Omega(i)$ 是以区域 i 为中心的四个相邻区域 (上、下、左、右)。我们用 Y 和 I 分别表示增强版本和输入图像中局部区域的平均强度值。我们经验上将局部区域的大小设置为 4×4 。给定其他区域大小, 该损失函数是稳定的。



图 4: 各项损失（空间一致性损失 L_{spa} 、曝光控制损失 L_{exp} 、颜色恒常性损失 L_{col} 、光照平滑性损失 L_{tv_A} ）贡献的消融研究。

曝光控制损失。为了约束欠曝/过曝区域，我们设计了一个曝光控制损失 L_{exp} 来控制曝光水平。该曝光控制损失衡量了局部区域的平均强度值与理想曝光水平 E 之间的距离。我们遵循现有做法 [23,24]，将 E 设定为 RGB 色彩空间中的灰度级。在实验中我们将 E 设为 0.6，虽然在 $[0.4, 0.7]$ 范围内设置 E 并未发现性能上有显著差异。损失 L_{exp} 可表示为：

$$L_{exp} = \frac{1}{M} \sum_{k=1}^M |Y_k - E|, \quad (5)$$

其中 M 表示大小为 16×16 的不重叠局部区域的数量， Y 是增强图像中局部区域的平均强度值。

颜色恒常性损失。遵循灰世界颜色恒常性假设 [2]，即整个图像中每个传感器通道的颜色平均值趋于灰色，我们设计了一种颜色恒常性损失，用于校正增强图像中的潜在颜色偏差，并建立三个调整通道之间的关系。颜色恒常性损失 L_{col} 可表示为：

$$L_{col} = \sum_{\forall (p,q) \in \varepsilon} (J^p - J^q)^2, \varepsilon = \{(R, G), (R, B), (G, B)\}, \quad (6)$$

其中 J^p 表示增强图像中第 p 通道的平均强度值， (p, q) 表示一对通道。照明平滑度损失。为保持相邻像素间的单调性关系，我们向每个曲线参数图 $\mathcal{A}$ 添加了一个照明平滑度损失。照明平滑度损失 L_{tv_A} 定义为：

$$L_{tv_A} = \frac{1}{N} \sum_{n=1}^N \sum_{c \in \xi} (|\nabla_x \mathcal{A}_n^c| + |\nabla_y \mathcal{A}_n^c|)^2, \xi = \{R, G, B\}, \quad (7)$$

其中 N 为迭代次数， ∇_x 和 ∇_y 分别表示水平和垂直梯度运算。总损失。总损失可表示为：

$$L_{total} = L_{spa} + L_{exp} + W_{col} L_{col} + W_{tv_A} L_{tv_A}, \quad (8)$$

其中 W_{col} 和 W_{tv_A} 是损失函数的权重。

4. 实验

实施细节。基于 CNN 的模型通常使用自捕获的成对数据进行网络训练 [5, 17, 28, 30, 32, 33]，而基于 GAN 的模型则精心挑选非成对数据 [6, 11, 12, 16, 35]。为了充分发挥宽动态范围调节的能力，我们将低光照和过曝图像都纳入了训练集。为此，我们采用 SICE 数据集 [4] 的 Part1 中的 360 组多曝光序列来训练所提出的 DCE-Net。该数据集也被用作 EnlightenGAN [12] 训练数据的一部分。我们将 Part1 子集 [4] 中不同曝光级别的 3,022 张图像随机分为两部分（2,422 张用于训练，其余用于验证）。我们将训练图像调整大小为 512×512 。

我们在 NVIDIA 2080Ti GPU 上使用 PyTorch 实现了我们的框架。批量大小设置为 8。每一层的滤波器权重均采用均值为零、标准差为 0.02 的高斯函数进行初始化。偏置初始化为常数。我们使用默认参数的 ADAM 优化器，并设定固定学习率为 $1e^{-4}$ 以进行网络优化。权重 W_{col} 和 W_{tv_A} 分别设为 0.5 和 20，以平衡损失函数的量级。

4.1. 消融研究

我们进行了一系列消融研究，以证明 Zero-DCE 各组件的有效性，如下所示。更多定性和定量比较结果见补充材料。

各项损失的贡献。我们在图 4 中展示了由各种损失组合训练得到的 Zero-DCE 的结果。没有空间一致性损失 L_{spa} 的结果具有相对较低的对比度（例如，云区域），与完整结果相比。这表明 L_{spa} 在保持输入图像与增强图像之间相邻区域差异方面的重要性。移除曝光控制损失 L_{exp} 无法恢复低光区域。丢弃颜色恒常性损失 L_{col} 时会出现严重的偏色现象。该变体在应用曲线映射时忽略了三个通道之间的关系。最后，移除光照平滑性损失 L_{tv_A} 会损害相邻区域之间的相关性，从而导致明显的伪影。

参数设置的影响。我们评估了...的效果




图 5: 参数设置效果的消融研究。 $l-f-n$ 代表所提出的 Zero-DCE, 其中 l 为卷积层数, f 为各层 (除最后一层外) 的特征图数量, n 为迭代次数。

Zero-DCE 中的参数, 包括 DCE-Net 的深度和宽度以及迭代次数。图 5 展示了一个视觉示例。在图 5(b) 中, 仅使用三个卷积层, Zero-DCE₃₋₃₂₋₈ 已能产生令人满意的结果, 表明零参考学习的有效性。

Zero-DCE₇₋₃₂₋₈ 和 Zero-DCE₇₋₃₂₋₁₆ 产生了视觉上最愉悦的结果, 具有自然的曝光和适当的对比度。通过将迭代次数减少到 1, 在 Zero-DCE₇₋₃₂₋₁ 上观察到了性能的明显下降, 如图 5(d) 所示。这是因为仅含单次迭代的曲线调整能力有限。这表明我们的方法需要高阶曲线。综合考虑效率与恢复性能之间的良好权衡, 我们选择 Zero-DCE₇₋₃₂₋₈ 作为最终模型。

训练数据的影响。为了测试训练数据的影响, 我们在不同的数据集上重新训练了 Zero-DCE: 1) 原始训练集中的 2,422 张图像中的仅 900 张低光图像 (Zero-DCE_{Low}), 2) DARK FACE 数据集 [37] 中提供的 9,000 张未标记低光图像 (Zero-DCE_{LargeL}), 以及 3) SICE 数据集 [4] 中 Part1 和 Part2 子集数据增强组合的 4,800 张多曝光图像 (Zero-DCE_{LargeLH})。如图 6(c) 和 (d) 所示, 在去除过曝的训练数据后, 尽管使用了更多的低光图像 (即 Zero-DCE_{LargeL}), Zero-DCE 仍倾向于过度增强照明良好的区域 (例如, 面部)。这些结果表明, 在我们的网络训练过程中使用多曝光训练数据是合理且必要的。此外, 当使用更多多曝光训练数据时 (即 Zero-DCE_{LargeLH}), Zero-DCE 能更好地恢复暗区, 如图 6(e) 所示。为了与其他基于深度学习的方法进行公平比较, 我们使用了与它们相当数量的训练数据, 尽管更多的训练数据可以为我们的方法带来更好的视觉性能。

4.2. 基准评估

我们将 Zero-DCE 与几种最先进的方法进行了比较: 三种传统方法 (SRIE [8], LIME [9], Li et al. [19]), 两种基于 CNN 的方法 (RetinexNet [32], Wang et al. [28]), 以及一种基于 GAN 的方法 (EnlightenGAN [12])。所有结果均使用公开可用的源代码及推荐参数复现。

我们在先前研究的标准图像集上进行了定性和定量实验, 包括 NPE [29] (84 张图像)、LIME [9] (10 张图像)、MEF [22] (17 张图像)、DICM [14] (64 张图像) 和 VV (24 张图像)。此外, 我们在 SICE 数据集 [4] 的 Part2 子集上对我们的方法进行了定量验证, 该子集包含 229 组多曝光序列及其对应的每序列参考图像。为了公平比较, 我们仅使用 Part2 子集 [4] 的低光图像进行测试, 因为基线方法无法很好地处理过曝图像。具体而言, 如果多曝光序列中有七张 (或九张) 图像, 我们选择前三张 (或前四张) 低光图像, 并将所有图像调整大小为 1200×900×3。最终, 我们获得了 767 对低光/正常光照图像。我们弃用了文献 [37] 中提到的低光/正常光照图像数据集, 因为 RetinexNet [32] 和 EnlightenGAN [12] 的训练数据集包含了该数据集中的一些图像。需要注意的是, 文献 [28] 中构建的最新成对训练和测试数据集并未公开。我们没有使用 MIT-Adobe FiveK 数据集 [3], 因为它并非主要为低曝光照片增强而设计。

4.2.1 视觉与感知比较

我们在图 7 中展示了典型低光图像上的视觉对比结果。对于具有挑战性的背光区域 (例如, 图 7(a) 中的面部), Zero-DCE 能够产生自然的曝光和清晰的细节, 而 SRIE [8]、LIME [9]、Wang et al. [28] 和 EnlightenGAN [12] 则无法清晰地恢复面部。RetinexNet [32] 产生了过曝的伪影。在第二个以室内场景为例中, 我们的方法在增强暗区的同时保留了输入图像的颜色。该结果在视觉上令人满意, 且无明显噪声和色偏。相比之下, Li et al. [19] 过度平滑了细节, 而其他基线方法则放大了噪声, 甚至产生了颜色偏差 (例如, 墙壁的颜色)。

我们进行了一项用户研究, 以量化各种方法的主观视觉质量。我们使用不同方法处理来自图像集 (NPE、LIME、MEF、DICM、VV) 的低光照图像。对于每个增强结果, 我们在屏幕上显示该结果, 并提供输入图像作为参考。共有 15 名受试者被邀请独立对增强图像的视觉质量进行评分。这些受试-

<https://sites.google.com/site/vonikakis/datasets>



图 6：训练数据影响的消融研究。




图 7：典型低光照图像的视觉比较。红色方框标示了明显的差异。

评分是通过观察以下结果来确定的：1）结果是否包含过曝/欠曝伪影或过度/不足增强的区域；2）结果是否引入颜色偏差；3）结果是否具有不自然的纹理和明显的噪声。视觉质量评分范围为 1 到 5（从最差到最佳）。各图像集的平均主观评分见表 1。如表 1 总结所示，Zero-DCE 在上述图像集的总共 202 张测试图像中获得了最高的平均用户研究 (US) 分数。对于 MEF、DICM 和 VV 数据集，我们的结果最受受试者青睐。除了 US 分数外，我们还采用无参考感知指数 (PI) [1,21,25] 来评估感知质量。PI 指标最初用于衡量图像超分辨率中的感知质量。它也被用于评估其他图像恢复任务的性能，例如图像去雾 [26]。较低的 PI 值表示更好的感知质量。PI 值也报告在表 1 中。与……相似

在用户研究中，就平均 PI 值而言，所提出的 Zero-DCE 优于其他竞争方法。

4.2.2 定量比较

对于全参考图像质量评估，我们采用峰值信噪比 (PSNR, dB)、结构相似性 (SSIM) [31] 和平均绝对误差 (MAE) 指标，在 Part2 子集 [4] 上对不同方法的性能进行定量比较。如表 2 所示，尽管本文提出的 Zero-DCE 未使用任何成对或非成对的训练数据，但在所有情况下均取得了最佳值。得益于简单的曲线映射形式和轻量级网络结构，Zero-DCE 还具有计算效率高的特点。表 3 显示了不同方法的运行时间[§]，该时间是针对 32 张尺寸为 1200×900×3 的图像取平均值的结果。对于传统方法，仅提供了 CPU 版本的代码。

[§] 运行时间是在配备 Nvidia GTX 2080Ti 显卡和 Intel I7 6700 CPU 的 PC 上测量的，但 Wang 等 [28] 除外，其必须在 GTX 1080Ti 显卡上运行。

表1: 图像集 (NPE、LIME、MEF、DICM、VV) 上的用户研究 (US) ↑/感知指数 (PI) ↓得分。较高的US分数表示更好的人类主观视觉质量, 而较低的PI值表示更好的感知质量。每种情况下最佳结果用红色标出, 次佳结果用蓝色标出。

Method	NPE	LIME	MEF	DICM	VV	Average
SRIE [8]	3.65/2.79	3.50/2.76	3.22/2.61	3.42/3.17	2.80/3.37	3.32/2.94
LIME [9]	3.78/3.05	3.95/3.00	3.71/2.78	3.31/3.35	3.21/3.03	3.59/3.04
Li et al. [19]	3.80/3.09	3.78/3.02	2.93/3.61	3.47/3.43	2.87/3.37	3.37/3.72
RetinexNet [32]	3.30/3.18	2.32/3.08	2.80/2.86	2.88/3.24	1.96/2.95	2.58/3.06
Wang et al. [28]	3.83/2.83	3.82/2.90	3.13/2.72	3.44/3.20	2.95/3.42	3.43/3.01
EnlightenGAN [12]	3.90/2.96	3.84/2.83	3.75/2.45	3.50/3.13	3.17/4.71	3.63/3.22
Zero-DCE	3.81/2.84	3.80/2.76	4.13/2.43	3.52/3.04	3.24/3.33	3.70/2.88

表2: 基于全参考图像质量评估指标的定量比较。最佳结果以红色显示, 次佳结果以蓝色显示 (每种情况下)。

Method	PSNR↑	SSIM↑	MAE↓
SRIE [8]	14.41	0.54	127.08
LIME [9]	16.17	0.57	108.12
Li et al. [19]	15.19	0.54	114.21
RetinexNet [32]	15.99	0.53	104.81
Wang et al. [28]	13.52	0.49	142.01
EnlightenGAN [12]	16.21	0.59	102.78
Zero-DCE	16.57	0.59	98.78

表3: 运行时间 (RT) 比较 (单位: 秒)。最佳结果以红色显示, 次佳结果以蓝色显示。

Method	RT	Platform
SRIE [8]	12.1865	MATLAB (CPU)
LIME [9]	0.4914	MATLAB (CPU)
Li et al. [19]	90.7859	MATLAB (CPU)
RetinexNet [32]	0.1200	TensorFlow (GPU)
Wang et al. [28]	0.0210	TensorFlow (GPU)
EnlightenGAN [12]	0.0078	PyTorch (GPU)
Zero-DCE	0.0025	PyTorch (GPU)

4.2.3 黑暗环境下的面部检测

我们研究了低光图像增强方法在低光条件下人脸检测任务中的性能。具体而言, 我们采用了包含 10,000 张暗光拍摄图像的最新 DARK FACE 数据集 [37]。由于测试集的边界框未公开, 我们在由 6,000 张图像组成的训练集和验证集上进行评估。作为基线模型, 我们使用了在 WIDER FACE 数据集 [34] 上训练的尖端深度人脸检测器——双 shots 人脸检测器 (DSFD) [18]。我们将不同低光图像增强方法的结果输入 DSFD [18], 并在图 8 中描绘了精度-召回率 (P-R) 曲线。此外, 我们还利用 DARK FACE 数据集 [37] 提供的评估工具比较了平均精度 (AP)。

https://github.com/Ir1d/DARKFACE_eval_tools




图 8: 暗光环境下人脸检测的性能。P-R 曲线、平均精度 (AP), 以及经我们的 Zero-DCE 增强前后的人脸检测示例。

如图8所示, 经过图像增强后, DSFD [18] 的精度与未增强的原始图像相比有显著提高。在不同方法中, RetinexNet [32] 和 Zero-DCE 的表现最佳。两种方法性能相当, 但 Zero-DCE 在高召回率区域表现更优。观察示例可知, 我们的 Zero-DCE 能够提亮极暗区域中的面部, 同时保留光照良好的区域, 从而提高了暗光环境下人脸检测器的性能。

5. 结论

我们提出了一种用于低光图像增强的深度网络。该网络可以使用零参考图像进行端到端训练。这是通过将低光图像增强任务表述为特定图像的曲线估计问题, 并设计一组可微的无参考损失函数来实现的。实验表明, 与现有的光照增强方法相比, 我们的方法具有优越性。在未来的工作中, 我们将尝试引入语义信息以解决困难案例, 并考虑噪声的影响。

致谢。本研究得到了国家自然科学基金 (NSFC) (61771334, 61632018, 61871342)、SenseTime-NTU 合作项目、新加坡教育部学术研究和研究基金 (MOE AcRF) 第一层级 (2018-T1-002-056)、NTU SUG、NTU NAP、中央高校基本科研业务费专项资金 (2019RC039)、中国博士后科学基金 (2019M660438)、香港研究资助局 (RGC) (408123) (CityU 21211518) 以及香港 GRF-RGC 一般研究基金 (9042322, 9042489, 9042816) 的支持。

参考文献

- [1] Yochai Blau 和 Tomer Michaeli. 感知-失真权衡. 见 CVPR, 2018.
- [2] Gershon Buchsbaum. 一种用于物体颜色感知的空间处理器模型. *J. Franklin Institute*, 310(1):1 – 26, 1980.
- [3] Vladimir Bychkovsky, Sylvain Paris, Eric Chan, 和 Frédo Durand. 使用输入/输出图像对数据库学习摄影全局色调调整. 见 CVPR, 2011.
- [4] 蔡建瑞, 顾树航, 张雷. 从多曝光图像学习深度单图像对比度增强器. *IEEE图像处理汇刊*, 27(4):2049 – 2026, 2018. 5, 6, 7
- [5] Chen Chen, Qifeng Chen, Jia Xu, 和 Koltun Vladlen. 在黑暗中学习视觉. 载于 CVPR, 2018.
- [6] Yusheng Chen, Yuching Wang, Manhsin Kao 和 Yungyu Chuang. 《深度照片增强器: 基于生成对抗网络从照片进行图像增强的非配对学习》. 载于 CVPR, 2018年.
- [7] Dinu Coltuc, Philippe Bolon 和 Jean-Marc Chassery. 精确直方图规范. *IEEE 图像处理汇刊*, 15(5):1143 – 1152, 2006.
- [8] Xueyang Fu, Delu Zeng, Yue Huang, Xiao-Ping Zhang 和 Xinghao Ding. 用于同时反射率和光照估计的加权变分模型. 载于 CVPR, 2016年.
- [9] Xiaojie Guo, Yu Li, 和 Haibin Ling. Lime: 基于照明图估计的低光照图像增强. *IEEE 图像处理汇刊*, 26(2):982 – 993, 2017. 2, 6, 7, 8
- [10] Haidi Ibrahim 和 Nicholas Sia Pik Kong. 用于图像对比度增强的亮度保持动态直方图均衡. *IEEE Consumer Electronics Transactions* (IEEE消费电子技术汇刊), 53(4):1752 – 1758, 2007.
- [11] Andrey Ignatov, Nikolay Kobyshev, Radu Timofte, Kenneth Vanhoey 和 Luc Van Gool. Wespe: 用于数码相机的弱监督照片增强器. 载于 CVPRW, 2018年. 5
- [12] Yifan Jiang, Xinyu Gong, Ding Liu, Yu Cheng, Chen Fang, Xiaohui Shen, Jianchao Yang, Pan Zhou 和 Zhangyang Wang. EnlightenGAN: 无成对监督的深度光照增强. 载于 CVPR, 2019年.
- [13] Edwin H Land. 颜色视觉的视网膜皮层理论. *科学美国人*, 237(6):108 – 128, 1977. 2
- [14] Chulwoo Lee, Chul Lee 和 Chang-Su Kim. 基于分层差表示的对比度增强. 载于 ICIP, 2012. 6
- [15] Chulwoo Lee, Chul Lee 和 Chang-Su Kim. 基于二维直方图分层差表示的对比度增强. *IEEE 图像处理汇刊*, 22(12):5372 – 5384, 2013. 2
- [16] 李聪义, 郭春乐, 和郭继昌. 基于弱监督颜色传递的水下图像颜色校正. *IEEE 信号处理快报*, 25(3):323 – 327, 2018.
- [17] Chongyi Li, Jichang Guo, Fatih Porikli 和 Yanwei Pang. Lightttnet: 一种用于弱光照...
- 定图像增强. *模式识别通报*, 104:15 – 22, 2018.
- [18] Jian Li, Yabiao Wang, Changan Wang, Ying Tai, Jianjun Qian, Jian Yang, Chengjie Wang, Jilin Li, 和 Feiyuen Huang. Dsf: 双 shots 人脸检测器. 载于 CVPR, 2019.
- [19] Mading Li, Jiaying Liu, Wenhan Yang, Xiaoyan Sun, 和 Zongming Guo. 基于稳健 Retinex 模型的揭示结构低光图像增强. *IEEE 图像处理汇刊*, 27(6):2828 – 2841, 2018.
- [20] Kin Gwn Lore, Adedotun Akintayo 和 Soumik Sarkar. LL-Net: 一种用于自然低光图像增强的深度自编码器方法. *Pattern Recognition*, 61:650 – 662, 2017. 2
- [21] Ma Chao, Yang Chih-Yuan, Yang Xiaokang 和 Yang Ming-Hsuan. 用于单图像超分辨率的无参考质量度量学习. *Computer Vision and Image Understanding*, 158:1 – 16, 2017.
- [22] Kede Ma, Kai Zeng 和 Zhou Wang. 多曝光图像融合的感知质量评估. *IEEE 图像处理汇刊*, 24(11):3345 – 3356, 2015.
- [23] Tom Mertens, Jan Kautz 和 Frank Van Reeth. 曝光融合. 见 PCCGA, 2007.
- [24] Tom Mertens, Jan Kautz 和 Frank Van Reeth. 曝光融合: 一种用于高动态范围摄影的简单且实用的替代方案. *Computer Graphics Forum*, 28(1):161 – 171, 2009. 5
- [25] Anish Mittal, Rajiv Soundararajan, 和 Alan C. Bovik. 制作“完全盲”图像质量分析器. *IEEE 信号处理快报*, 20(3):209 – 212, 2013.
- [26] Yanyun Qu, Yizi Chen, Jingying Huang 和 Yuan Xie. 增强的 pix2pix 去雾网络. 载于 CVPR, 2019.
- [27] J Alex Stark. 利用直方图均衡化的推广进行自适应图像对比度增强. *IEEE图像处理汇刊*, 9(5):889 – 896, 2000.
- [28] Ruixing Wang, Qing Zhang, Chi-Wing Fu, Xiaoyong Shen, Wei-Shi Zheng, 和 Jiaya Jia. 基于深度光照估计的低曝光照片增强. 见 CVPR, 2019.
- [29] Shuhang Wang, Jin Zheng, Hai-Miao Hu 和 Bo Li. 非均匀光照图像的自然性保持增强算法. *IEEE 图像处理汇刊*, 22(9):3538 – 3548, 2013. 2, 6
- [30] 王稳关, 赖秋霞, 付华柱, 沈建兵, 和凌海滨. 深度学习时代的显著性目标检测: 深度综述, 2019. 5
- [31] Zhou Wang, Alan C. Bovik, Hamid R. Sheikh, 和 Eero P. Simoncelli. 图像质量评估: 从误差可见性到结构相似性. *IEEE 图像处理汇刊*, 13(4):600 – 612, 2004. 7
- [32] Chen Wei, Wenjing Wang, Wenhan Yang 和 Jiaying Liu. 用于低光照增强的深度 Retinex 分解. 见 BMVC, 2018.
- [33] 徐鹏. 自由手绘草图的深度学习: 综述, 2020. 5
- [34] Shuo Yang, Ping Luo, Chen-Change Loy, 和 Xiaoou Tang. 更宽的人脸: 一个人脸检测基准. 见 CVPR, 2016.
- [35] Yu Runsheng, Liu Wenyu, Zhang Yasen, Qu Zhi, Zhao Deli, 及 Zhang Bo. Deepexposure: 学习曝光光-

s with asynchronously reinforced adversarial learning. In NeurIPS, 2018. 5

[36] Lu Yuan 和 Jian Sun。消费者照片的自动曝光校正。载于 ECCV, 2012年。

[37] Ye Yuan, Wenhan Yang, Wenqi Ren, Jiaying Liu, Walter J. Scheirer 和 Wang Zhangyang。Ug+ 第2赛道：一项在低能见度环境中评估和提升图像理解能力的集体基准测试，2019。
arXiv arXiv:1904.04474。6, 8

[38] Jun-Yan Zhu, Taesung Park, Phillip Isola, 和 Alexei A. Efros。使用循环一致性对抗网络进行非配对图像到图像转换。载于 ICCV, 2017。